

VibeLearning

Plataforma de tutoría personalizada y andamiaje visual dinámico basada en arquitecturas RAG de baja latencia con persistencia autenticada en la nube.

Equipo: 353

Integrante 1: Sebastian Barreda

Integrante 2: Esteban Villagarcía

Integrante 3: Fernando Lizarraga

Integrante 4: Leonardo Cuadros

26 de junio de 2026

Resumen

El modelo pedagógico expositivo predominante en entornos de educación superior híbridos y virtuales genera una desconexión crítica entre el ritmo del docente y la capacidad real de asimilación del alumno. La saturación de la memoria de trabajo, agudizada por la proliferación de distracciones digitales, impide la consolidación efectiva del conocimiento y perpetúa un rezago académico acumulativo que el docente no puede atender de forma personalizada en grupos masivos.

VibeLearning es una plataforma educativa potenciada por inteligencia artificial que interviene en esta brecha en tiempo real. Mediante la captura y transcripción continua del audio de la clase (utilizando el modelo *whisper-large-v3-turbo* sobre la infraestructura de inferencia ultra-rápida de Groq), el sistema aplica un ventaneo semántico automático para extraer los conceptos clave de cada segmento de la exposición. Sobre estos conceptos genera micro-evaluaciones de evocación activa (*active recall*) desplegadas de forma no intrusiva; ante respuestas incorrectas, activa un módulo de andamiaje cognitivo que produce resúmenes ejecutivos y mapas mentales jerárquicos interactivos en formato SVG. Un chatbot flotante basado en arquitectura de Generación Aumentada por Recuperación (RAG) integra la transcripción acumulada con el material bibliográfico pre-clase cargado por el alumno para resolver dudas puntuales sin interrumpir la dinámica del aula. Al concluir la sesión, el sistema genera un informe de cierre con resumen y mapa mental global, que queda persistido en la nube vinculado a la cuenta del usuario mediante autenticación segura.

El impacto educativo esperado incluye una reducción del 100 % en el tiempo de preparación de evaluaciones formativas para el docente, un incremento proyectado del 35 % en la participación interactiva del estudiante y una tasa de recuperación autónoma del sesgo de comprensión del 85 % en la evaluación inmediatamente posterior al fallo. La solución es técnicamente viable, éticamente responsable y desplegable en producción sobre infraestructura serverless estándar.

Índice general

1. Planteamiento del Problema	2
1.1. Contextualización de la Realidad Educativa	2
1.2. Problema General	2
1.3. Problemas Específicos	3
2. Justificación del Proyecto	4
2.1. Justificación Social y Educativa	4
2.2. Justificación Técnica (El porqué de la IA)	5
2.3. Viabilidad y Factibilidad	5
3. Objetivos del Proyecto	6
3.1. Objetivo General	6
3.2. Objetivos Específicos	6
4. Marco Conceptual y Estado del Arte	7
4.1. Antecedentes y Soluciones Existentes	7
4.2. Bases Teórico-Tecnológicas	7
5. Propuesta de Solución e Implementación Técnica	9
5.1. Requisitos del Sistema	9
5.1.1. Requisitos Funcionales (RF)	9
5.1.2. Requisitos No Funcionales (RNF)	12
5.1.3. Arquitectura General de la Solución	13
5.2. Descripción Detallada del Prototipo Desarrollado (Demo)	14
5.2.1. Módulos Core Implementados en el MVP	15
5.2.2. Flujo de Ejecución Completo de la Demo	15
5.2.3. Contrato de Datos entre Frontend y Endpoints de IA	17
5.3. Estrategia de Integración de IA y Control de Comportamiento	17
5.3.1. Estructuración del Prompting y System Role	17
5.3.2. Mitigación de Alucinaciones y Formateo Determinista	17
6. Impacto Esperado y Conclusiones	19
6.1. Métricas de Éxito Educativo y Tecnológico	19
6.1.1. Indicadores de Rendimiento Tecnológico (KPIs Técnicos)	19
6.1.2. Indicadores de Éxito Educativo (KPIs Pedagógicos)	19
6.2. Conclusiones	20
6.2.1. Conclusiones del Desarrollo del Prototipo	20

1. Planteamiento del Problema

1.1. Contextualización de la Realidad Educativa

El panorama educativo actual se enfrenta a una severa crisis de atención, agudizada por la proliferación de estímulos digitales en las aulas virtuales e híbridas. La evidencia empírica reciente demuestra que el uso de dispositivos tecnológicos para actividades ajenas a la clase fragmenta de forma crítica el enfoque sostenido de los estudiantes, impactando directamente en su rendimiento académico. A pesar de esta realidad, el modelo pedagógico predominante sigue anclado en clases magistrales lineales de larga duración. Esta desconexión satura la memoria de trabajo de los alumnos, impidiendo que la información se procese correctamente y transformándolos en receptores pasivos propensos a la distracción.

A esta problemática se suma la dificultad histórica de personalizar la enseñanza en grupos masivos, donde un único docente carece de la capacidad operativa para detectar en tiempo real las lagunas de comprensión individuales. Cuando un estudiante no comprende un concepto inicial, arrastra ese vacío y pierde el hilo conductor del resto de la sesión. La psicología cognitiva ha demostrado que los métodos de estudio tradicionales, como la relectura pasiva o el subrayado de textos, son ineficaces para mitigar este rezago. Por el contrario, estrategias como el *active recall* (evocación activa mediante preguntas) y la retroalimentación inmediata son herramientas clave para consolidar el conocimiento y corregir los errores en el momento exacto en que ocurren [Karpicke, 2012].

En este escenario, los avances en Inteligencia Artificial y el Procesamiento de Lenguaje Natural abren una oportunidad inédita para intervenir positivamente en la dinámica del aula. VibeLearning nace como respuesta a este quiebre tecnológico. Al procesar la transcripción de la clase en vivo, la plataforma extrae automáticamente los conceptos clave y lanza micro-evaluaciones formativas de forma no intrusiva. Esto permite interceptar el error en tiempo real, aliviando la carga cognitiva del estudiante y transformando la escucha pasiva en un flujo dinámico, interactivo y adaptado al ritmo real del aprendizaje. El sistema también persiste el historial de sesiones en la nube, vinculado a la cuenta autenticada del usuario, permitiendo que el alumno consulte sus clases anteriores desde un panel personal.

1.2. Problema General

La persistencia del modelo de enseñanza magistral pasivo en entornos educativos digitales e híbridos impide que el estudiante consolide los conocimientos de manera efectiva debido a la fragmentación de su atención y a la saturación de su memoria de trabajo. En las aulas masivas contemporáneas, el proceso formativo carece de un mecanismo dinámico y en tiempo real que permita interceptar las lagunas de comprensión individuales en el momento exacto en que ocurren. Esto genera una desconexión crítica entre el ritmo de exposición del docente y la capacidad real de asimilación del alumno, imposibilitando la personalización del aprendizaje y derivando en un rezago académico acumulativo que obstaculiza el desarrollo del pensamiento crítico y la retención del conocimiento a largo plazo.

1.3. Problemas Específicos

- **P.E.1:** La pérdida progresiva de la atención sostenida y la proliferación de distracciones digitales durante las sesiones expositivas prolongadas aumentan drásticamente la carga cognitiva extrínseca del estudiante, lo que bloquea el procesamiento correcto de la información verbal y reduce el tiempo efectivo de aprendizaje útil dentro del aula.
- **P.E.2:** La ausencia de herramientas de evaluación formativa automatizadas y no intrusivas durante la clase impide que el alumno autoevalúe su nivel de comprensión de manera inmediata mediante técnicas de evocación activa (*active recall*), lo que perpetúa metodologías de estudio pasivas e ineficaces y consolida estructuras de conocimiento erróneas o incompletas.
- **P.E.3:** La falta de mecanismos de retroalimentación inmediata y andamiaje pedagógico adaptativo en tiempo real priva a los estudiantes de un soporte personalizado ante fallos específicos de comprensión, forzándolos a arrastrar vacíos conceptuales que les impiden seguir el hilo conductor de los temas subsiguientes expuestos por el docente.
- **P.E.4:** La dificultad para interactuar simultáneamente con las explicaciones del profesor y los materiales estáticos de la asignatura (como documentos PDF pre-clase) satura la capacidad operativa del alumno, quien no dispone de un asistente contextual centralizado que resuelva dudas puntuales en plena sesión sin interrumpir el flujo del aula.

2. Justificación del Proyecto

2.1. Justificación Social y Educativa

La urgencia de transformar la experiencia en el aula se sustenta en el desgaste del modelo tradicional ante la digitalización acelerada y la profunda crisis de permanencia estudiantil que atraviesa la educación superior en América Latina. De acuerdo con informes globales de la UNESCO, más del 70 % de los estudiantes universitarios manifiestan experimentar fatiga cognitiva y dificultades severas de concentración bajo formatos educativos híbridos o virtuales estructurados de forma puramente expositiva [UNESCO, 2023].

Este fenómeno tiene consecuencias institucionales y sociales medibles en la región. En Brasil, solo el 51 % de los estudiantes matriculados logran completar su graduación; una cifra que desciende a aproximadamente el 40 % en Chile y México [Desire2Learn, 2023]. El escenario en Argentina es aún más complejo: a pesar de contar con una de las tasas de matriculación más altas proporcionalmente, registra uno de los índices de retención más bajos de la región, donde apenas el 30 % de los alumnos finalizan sus estudios universitarios [Desire2Learn, 2023].

El caso peruano es particularmente crítico en este panorama regional. Según registros oficiales, Perú documentó una tasa de deserción estudiantil universitaria del 33 % tan solo en el primer año de carrera antes del inicio de la crisis sanitaria [MINEDU, 2019]. Las investigaciones locales demuestran que las causas de orden académico poseen un peso determinante, llegando a influir en hasta el 75 % de los casos analizados de abandono de estudios [Ramos-Huenteo and Espinoza-Valenzuela, 2021].

Esta realidad sitúa a VibeLearning en la frontera de un problema que trasciende lo estrictamente pedagógico para convertirse en un desafío de equidad, inclusión y eficiencia institucional. Un estudiante que no comprende, que no retiene conceptos clave y que carece de retroalimentación inmediata durante la clase magistral es un estudiante con un riesgo exponencial de deserción. VibeLearning impacta de manera directa en la comunidad educativa al mitigar esta desconexión: para el estudiante, transforma la frustración del aislamiento y el rezago conceptual en una experiencia interactiva de co-piloto pedagógico que ataca el abandono en su raíz; para el docente, reduce el desgaste y la carga administrativa de diseñar evaluaciones formativas constantes, permitiéndole concentrarse en la facilitación del conocimiento en lugar de la monitorización mecánica de la retención.

Al democratizar el acceso a un tutor personalizado en tiempo real que asiste al alumno sin interrumpir el ritmo de la clase, la solución aborda un problema crítico de equidad y efectividad del aprendizaje en la educación superior contemporánea. Adicionalmente, la capacidad de persistir el historial de sesiones en la nube permite que cada estudiante construya un repositorio personal de clases anotadas, resúmenes generados y mapas conceptuales, extendiendo el impacto del sistema más allá de la sesión en vivo.

2.2. Justificación Técnica (El porqué de la IA)

El desarrollo de software convencional o basado en flujos lógicos tradicionales es estructuralmente insuficiente para resolver esta problemática. Un sistema clásico no puede interpretar la semántica variable de un discurso hablado en vivo, mapear conceptos abstractos sobre la marcha, ni generar dinámicamente un cuestionario adaptado al contexto inmediato de una conversación abierta. Las capacidades avanzadas del Procesamiento de Lenguaje Natural (PLN) y el auge de los Modelos de Lenguaje de Gran Escala (LLMs) son los únicos componentes tecnológicos capaces de procesar flujos de audio en tiempo real para extraer vectores conceptuales estructurados.

La implementación de arquitecturas de Generación Aumentada por Recuperación (RAG) permite cruzar instantáneamente la transcripción del aula con el material estático previamente cargado —así como con el historial de sesiones anteriores del alumno persistido en la base de datos—, logrando un sistema adaptativo que evalúa la idea principal y personaliza el andamiaje formativo mediante la conversión automatizada de texto a mapas mentales jerárquicos [Lewis et al., 2020]. Esta combinación de inferencia en tiempo real y contexto enriquecido por recuperación documental constituye una frontera técnica que era computacionalmente inviable con la programación tradicional.

2.3. Viabilidad y Factibilidad

La ejecución de VibeLearning es plenamente realizable en el corto plazo —como marco de MVP para eventos de desarrollo acelerado como el Hackathon Nexia 2026— debido a la madurez y disponibilidad inmediata del ecosistema tecnológico actual. La existencia de infraestructura en la nube optimizada y APIs de inferencia ultra-rápida de baja latencia como Groq (usando los modelos `whisper-large-v3-turbo` para transcripción y las variantes `openai/gpt-oss-20b` y `openai/gpt-oss-120b` para tareas semánticas) permite procesar audio y texto en milisegundos con costos operativos marginales o cubiertos por capas gratuitas de demostración.

El uso de frameworks modernos basados en JavaScript, como Next.js con App Router, reduce los tiempos de integración del frontend y backend a pocas horas. La autenticación y persistencia en la nube se implementan mediante Supabase, que provee autenticación (Google OAuth y correo/contraseña), base de datos PostgreSQL con políticas de seguridad a nivel de fila (Row Level Security) y SDK optimizado para entornos serverless, todo sin necesidad de infraestructura propia. Desde la perspectiva ética, el proyecto garantiza la privacidad de los datos al aislar la información de cada usuario mediante autenticación y RLS: ningún alumno tiene acceso a las sesiones o transcripciones de otro, y la información sensible del aula nunca se almacena en texto plano no controlado.

3. Objetivos del Proyecto

3.1. Objetivo General

Desarrollar una solución tecnológica educativa basada en inteligencia artificial en tiempo real que mitigue la carga cognitiva extrínseca y la brecha de atención en entornos híbridos y virtuales, transformando la escucha pasiva del estudiante en un flujo de aprendizaje interactivo y personalizado mediante la automatización de evaluaciones formativas, andamiaje cognitivo visual, asistencia contextualizada de baja latencia y persistencia autenticada del historial de sesiones en la nube.

3.2. Objetivos Específicos

1. **O.E.1:** Implementar un módulo de ingestión y procesamiento de audio que capture la exposición verbal del docente en tiempo real y la convierta eficientemente en texto, permitiendo la segmentación semántica de la clase en ventanas temporales críticas para identificar ideas y conceptos clave de manera automatizada.
2. **O.E.2:** Diseñar un componente interactivo de evaluación formativa no intrusivo que genere y despliegue dinámicamente cuestionarios cortos basados en los conceptos extraídos de la sesión, promoviendo la evocación activa (*active recall*) por parte del estudiante en intervalos óptimos durante la clase.
3. **O.E.3:** Desarrollar un sub-sistema de retroalimentación inmediata y andamiaje pedagógico adaptativo que, ante respuestas incorrectas del usuario, genere resúmenes ejecutivos sintéticos y mapas mentales estructurados jerárquicamente para corregir el sesgo de comprensión en el acto.
4. **O.E.4:** Integrar un módulo de asistencia contextual flotante basado en la arquitectura de Generación Aumentada por Recuperación (RAG) que consolide de manera interactiva la transcripción acumulada de la sesión y los materiales bibliográficos pre-clase cargados por el alumno, resolviendo dudas puntuales mediante respuestas precisas y en lenguaje natural sin interrumpir la dinámica del aula.
5. **O.E.5:** Implementar un sistema de autenticación y persistencia en la nube que permita al estudiante registrar su cuenta, acceder a un panel de clases anteriores y recuperar el resumen, mapa mental y transcripción de cada sesión finalizada, garantizando el aislamiento de datos entre usuarios mediante políticas de seguridad a nivel de base de datos.

4. Marco Conceptual y Estado del Arte

4.1. Antecedentes y Soluciones Existentes

El desarrollo de herramientas tecnológicas orientadas a la asistencia en el aula ha evolucionado significativamente en la última década. Tradicionalmente, soluciones comerciales como Kahoot! o Quizizz han liderado la gamificación y la evaluación formativa mediante cuestionarios en tiempo real; sin embargo, estas plataformas dependen por completo de la preparación previa y manual de reactivos por parte del docente, lo que limita su adaptabilidad durante explicaciones espontáneas. En el ámbito académico, se han estudiado sistemas basados en asistentes inteligentes que apoyan dinámicas de aula invertida e interactividad en vivo [Teng et al., 2024], demostrando que el uso de agentes inteligentes incrementa la retención y la participación estudiantil. No obstante, estas alternativas suelen enfocarse en repositorios estáticos o en interacciones posteriores a la sesión, dejando un vacío en la asistencia contextual sincrónica.

El factor diferenciador e innovador de VibeLearning radica en la automatización completa del flujo de ingestión y la nula carga administrativa para el usuario. A diferencia de las soluciones comerciales que requieren una configuración laboriosa, VibeLearning intercepta directamente el flujo de audio en vivo, ejecutando un ventaneo semántico que autogenera micro-evaluaciones no invasivas de *active recall* en intervalos óptimos de la clase. Además, la propuesta se distingue por integrar un sistema de andamiaje inmediato que combina mapas mentales dinámicos y un chatbot contextual alimentado simultáneamente por la transcripción en vivo y los apuntes cargados, resolviendo el problema de la distracción digital mediante una experiencia interactiva unificada dentro de una sola interfaz. Finalmente, el sistema provee un repositorio personal de sesiones persistido en la nube, accesible en cualquier momento desde el panel del usuario autenticado, lo que ninguna solución de evaluación formativa en tiempo real existente ofrece de forma integrada.

4.2. Bases Teórico-Tecnológicas

El sustento operativo de VibeLearning se fundamenta en la convergencia de principios de la psicología cognitiva y paradigmas modernos de la ingeniería de software. En primer lugar, los Modelos Fundacionales de Lenguaje (LLMs) y el procesamiento de lenguaje natural permiten codificar y estructurar el flujo conversacional de la clase en vivo mediante algoritmos de inferencia de baja latencia, abstrayendo conceptos complejos en milisegundos. Esta capacidad es posible gracias a la infraestructura de procesamiento de Groq, que sirve los modelos `openai/gpt-oss-20b` y `openai/gpt-oss-120b` con latencias de inferencia significativamente menores a las de los proveedores convencionales. La capacidad de interpretación semántica es complementada con la arquitectura de Generación Aumentada por Recuperación (RAG), una técnica avanzada de ingeniería de prompts que optimiza las respuestas de los modelos combinando el conocimiento paramétrico del LLM con fuentes de verdad externas (el material de lectura pre-clase y la transcripción acumulada) sin necesidad de reentrenar la red

neuronal [Lewis et al., 2020].

Desde la perspectiva pedagógica, el sistema instrumentaliza el concepto de *Active Recall* (Evocación Activa), un principio de la ciencia del aprendizaje que postula que la memoria a largo plazo se consolida con mayor efectividad cuando el cerebro es estimulado a recuperar activamente la información mediante desafíos formativos cortos, en lugar de recibirla pasivamente [Karpicke, 2012]. Tecnológicamente, esto se implementa mediante una arquitectura de rutas de API desacopladas en Next.js, donde la lógica de evaluación y asistencia se divide en endpoints independientes que funcionan como microservicios serverless. Esta arquitectura modular permite segmentar el análisis del flujo conversacional sin bloquear el hilo principal del frontend, garantizando que el procesamiento y renderizado dinámico de mapas mentales jerárquicos (en formato SVG mediante `markmap-lib` y `markmap-view`) se despliegue de manera inmediata en la interfaz en el instante exacto en que ocurre un fallo de comprensión.

La capa de persistencia se apoya en Supabase, una plataforma de base de datos como servicio (DBaaS) que expone una instancia de PostgreSQL con autenticación integrada. El control de acceso a los datos se implementa mediante Row Level Security (RLS), un mecanismo nativo de PostgreSQL que filtra automáticamente las filas a nivel del motor de base de datos según el identificador del usuario autenticado, garantizando que cada alumno acceda exclusivamente a sus propias sesiones de clase sin ninguna lógica adicional en el código de la aplicación.

5. Propuesta de Solución e Implementación Técnica

En este capítulo se detalla el diseño e implementación de la solución tecnológica desarrollada durante el evento. Se abordan desde las especificaciones de requisitos hasta la arquitectura técnica y el funcionamiento exacto de la versión demostrativa (MVP) generada.

5.1. Requisitos del Sistema

Para guiar el desarrollo ágil del prototipo, se definieron los requerimientos mínimos viables clasificados en dos categorías:

5.1.1. Requisitos Funcionales (RF)

Módulo de Ingestión de Audio y Transcripción en Vivo

- **RF-1 (Captura de Audio):** El sistema debe capturar el flujo de audio del usuario en tiempo real desde el micrófono utilizando la API nativa `MediaRecorder` del navegador.
- **RF-2 (Segmentación de Audio):** El sistema debe segmentar automáticamente el flujo de audio en búferes o *chunks* temporales fijos de 7000 milisegundos (7s).
- **RF-3 (Envío Automático de Audio):** La interfaz web debe enviar cada fragmento de audio generado al endpoint `/api/transcribe` a través de una petición de tipo `FormData` bajo el campo `.audio`.
- **RF-4 (Conversión Speech-to-Text):** El endpoint `/api/transcribe` debe procesar el archivo binario recibido utilizando el modelo `whisper-large-v3-turbo` en la infraestructura de Groq.
- **RF-5 (Concatenación de Texto):** El sistema en el frontend debe recibir la cadena de texto de la respuesta `{"text": "..."}` y concatenarla de forma inmediata al estado global `transcript` de la sesión activa.

Módulo de Ventaneo e Identificación de Conceptos

- **RF-6 (Control del Acumulador):** El sistema debe monitorear la longitud del estado `transcript` y activar un flujo de análisis cada vez que la nueva ventana acumulada supere un rango de entre 90 y 120 segundos (equivalente a un intervalo de entre 12 y 15 *chunks* procesados).
- **RF-7 (Extracción Semántica de Conceptos):** El sistema debe enviar la ventana de texto acumulada al endpoint `/api/concepts`, el cual debe procesar el fragmento mediante el modelo `openai/gpt-oss-20b` (servido por Groq) para extraer entre 3 y 5 conceptos clave estructurados.

- **RF-8 (Estructuración de Conceptos):** El sistema debe parsear la salida del LLM y devolver estrictamente un objeto JSON con la estructura `{conceptos: [{"name": "...", "summary": "..."}]}` para ser renderizado en la interfaz.

Módulo de Evaluación Dinámica (Active Recall)

- **RF-9 (Disparo Automático de Quizzes):** El sistema debe gatillar automáticamente la creación de una prueba tras la obtención de los nuevos conceptos mapeados en la sesión.
- **RF-10 (Generación de Reactivos Cortos):** El endpoint `/api/quiz` debe consumir la lista de conceptos y, a través del modelo `openai/gpt-oss-20b` (vía Groq), estructurar una única pregunta de opción múltiple con tres alternativas (A, B, C) enfocada en evaluar la idea principal en menos de 10 segundos.
- **RF-11 (Visualización No Intrusiva):** El frontend debe desplegar la pregunta generada a través de un componente de banner superior o tarjeta flotante que no bloquee ni interrumpa la lectura de la transcripción en vivo.
- **RF-12 (Validación de Respuestas):** El sistema debe evaluar la alternativa seleccionada por el estudiante contra el campo `correct` del contrato de datos, renderizando visualmente un indicador de confirmación verde ante un acierto.

Módulo de Andamiaje y Refuerzo Cognitivo

- **RF-13 (Activación de Refuerzo por Fallo):** Al detectar una respuesta incorrecta en el cuestionario, la aplicación debe realizar una petición POST automatizada al endpoint `/api/reinforcement` enviando los campos `concept_name` y `concept_summary`.
- **RF-14 (Generación de Contenido de Apoyo):** El endpoint `/api/reinforcement` debe invocar al modelo `openai/gpt-oss-120b` (vía Groq) para producir un resumen ejecutivo de 3 a 4 líneas en lenguaje simple y un mini mapa mental ordenado en formato de lista jerárquica Markdown.
- **RF-15 (Renderizado de Mapas Mentales):** El frontend debe recibir la estructura `{"markdown": "..."} y procesarla a través del componente <MindMap> utilizando las librerías markmap-lib y markmap-view para pintar dinámicamente un árbol visual interactivo dentro de un panel de refuerzo.`

Contextualización de Documentos (RAG) y Chatbot Flotante

- **RF-16 (Carga de Documentos Pre-Clase):** La interfaz debe permitir al estudiante cargar un archivo en formato PDF antes o durante la sesión educativa para contextualizar las consultas individuales.
- **RF-17 (Procesamiento y Extracción de PDF):** El endpoint `/api/upload-material` debe interpretar el archivo binario usando la librería `pdf-parse/lib/pdf-parse.js` y

generar un resumen denso de temas clave de máximo 300 palabras mediante el modelo `openai/gpt-oss-120b`.

- **RF-18 (Persistencia de Contexto Estático):** La aplicación debe almacenar el valor del "summary" resultante del PDF en el estado local de React para actuar como la base de conocimiento fija de la sesión activa.
- **RF-19 (Interfaz de Chat Integrada):** El sistema debe proveer una ventana de chat flotante accesible en todo momento para que el estudiante redacte preguntas en texto plano sobre el desarrollo de la clase.
- **RF-20 (Truncado Dinámico del Contexto):** El frontend debe recuperar de su estado interno las últimas ~3000 palabras de la transcripción en vivo acumulada y adjuntarlas junto con el resumen del PDF en la petición dirigida al endpoint `/api/chatbot`.
- **RF-21 (Generación de Respuestas Limpias):** El endpoint `/api/chatbot` debe procesar los datos con el modelo `openai/gpt-oss-120b` restringiendo su salida a un máximo de 110 tokens (`max_tokens: 110`) en texto plano y libre de formato Markdown.

Módulo de Autenticación y Gestión de Sesiones de Usuario

- **RF-22 (Registro e Inicio de Sesión):** La aplicación debe proveer una página de autenticación (`/login`) que soporte tanto registro e inicio de sesión mediante correo electrónico y contraseña como autenticación federada a través de Google OAuth 2.0, ambas gestionadas por Supabase Auth.
- **RF-23 (Protección de Rutas):** El middleware de Next.js debe interceptar todas las peticiones a rutas protegidas (`/dashboard` y `/class/*`) y redirigir al usuario no autenticado a `/login`, verificando la sesión activa mediante el cliente de Supabase server-side.
- **RF-24 (Panel de Clases Pasadas):** La ruta `/dashboard` debe renderizar, mediante un Server Component, la lista de clases finalizadas del usuario autenticado, ordenadas cronológicamente, recuperadas desde la tabla `classes` de Supabase.
- **RF-25 (Vista de Clase Guardada):** La ruta dinámica `/class/[id]` debe renderizar el resumen en Markdown, el mapa mental SVG y ofrecer la descarga de la transcripción completa de cualquier sesión anterior del usuario.

Módulo de Cierre, Persistencia y Gestión de Errores

- **RF-26 (Finalización de Sesión):** La interfaz debe incluir un botón explícito para "Finalizar Clase" que detenga la captura del micrófono y despache la transcripción íntegra junto con todos los conceptos acumulados al endpoint `/api/finish-class`.
- **RF-27 (Estructuración del Informe de Cierre):** El endpoint `/api/finish-class` debe utilizar el modelo `openai/gpt-oss-120b` para procesar el histórico y devolver un JSON con un título de máximo 6 palabras, un resumen sintético de máximo 400 palabras en formato Markdown, y un listado jerárquico para el mapa mental.

- **RF-28 (Persistencia del Resumen en la Nube):** Tras recibir la respuesta de `/api/finish-class`, el frontend debe insertar en la tabla `classes` de Supabase un registro que incluya el `user_id` del alumno autenticado, el título, la transcripción completa, los conceptos, los resultados del quiz, el resumen del PDF y el resumen final con su mapa mental; acto seguido, debe redirigir al usuario a `/dashboard`.
- **RF-29 (Visualización de Reporte Final):** El sistema debe ocultar la pantalla de captura en vivo y renderizar la vista de resumen final utilizando `react-markdown` para el texto explicativo y el componente `<MindMap>` para el mapa conceptual generalizado.
- **RF-30 (Continuidad de la Interfaz ante Errores):** El frontend debe capturar los retornos controlados de saturación de la API de IA e impedir la interrupción del sistema o el congelamiento de la interfaz, garantizando que el flujo de la aplicación se mantenga operativo en todo momento.

5.1.2. Requisitos No Funcionales (RNF)

Módulo de Seguridad y Privacidad de Datos

- **RNF-1 (Protocolo de Transferencia Seguro):** Todas las comunicaciones entre el cliente web y los endpoints de la API hospedados en Vercel deben ser cifradas mediante el protocolo HTTPS con TLS 1.2 o superior, garantizando la protección de los datos en tránsito y el acceso seguro a la API nativa del micrófono del dispositivo.
- **RNF-2 (Aislamiento de Datos por Usuario Autenticado):** El contenido de las transcripciones de voz y los resúmenes de los archivos PDF no deben ser accesibles entre usuarios. El aislamiento se garantiza mediante Row Level Security (RLS) en PostgreSQL a nivel del motor de base de datos: las políticas `select_own`, `insert_own`, `update_own` y `delete_own` vinculan cada registro de la tabla `classes` al `auth.uid()` del usuario que lo creó, sin depender de lógica de filtrado en la capa de aplicación.
- **RNF-3 (Ofuscación y Manejo de Credenciales):** Las credenciales de autenticación y llaves de acceso privadas (`GROQ_API_KEY`) deben mantenerse estrictamente del lado del servidor, encapsuladas en variables de entorno seguras de la plataforma de despliegue. La clave pública de Supabase (`NEXT_PUBLIC_SUPABASE_ANON_KEY`) es expuesta al cliente únicamente en su rol de clave anónima, cuyo acceso a datos está restringido por las políticas RLS; en ningún caso se expone al navegador la clave de servicio (*service role key*).

Módulo de Rendimiento, Eficiencia y Disponibilidad

- **RNF-4 (Baja Latencia de Inferencia):** El backend debe optimizar las llamadas a los modelos de procesamiento (`whisper-large-v3-turbo` y la suite `openai/gpt-oss`) a través de la infraestructura de Groq, asegurando tiempos de respuesta combinados inferiores a los 5 segundos para la transcripción y la generación de los micro-quizzes.

- **RNF-5 (Optimización del Tamaño del Contexto):** El sistema de asistencia conversacional debe implementar un mecanismo de truncamiento dinámico en memoria que limite el histórico de transcripción enviado en el *payload* de IA a un máximo de las últimas ~3000 palabras, minimizando el consumo de tokens y previniendo la degradación del rendimiento por saturación de contexto.
- **RNF-6 (Tolerancia a Límites de Consumo — Rate Limits):** Ante excepciones de cuota excesiva (errores HTTP 429) de las capas gratuitas de los proveedores, los endpoints deben interceptar el error y responder con un objeto controlado de tipo `{skip:true}` o `{error}`, permitiendo que la interfaz continúe respondiendo sin colapsar.

Módulo de Mantenibilidad, Modularidad y Escalabilidad

- **RNF-7 (Arquitectura Modular y Roles de Desarrollo):** El código fuente debe estar desacoplado siguiendo el diseño de responsabilidades por rol de ingeniería. Cada endpoint de la API (`/api/*`) debe funcionar como un microservicio independiente con contratos de datos inmutables en JSON. La capa de persistencia (Supabase) es gestionada exclusivamente desde el frontend (P1), sin que los endpoints de inferencia (P2 y P3) accedan a la base de datos.
- **RNF-8 (Robustez del Intérprete JSON):** Los módulos que consumen respuestas estructuradas desde los modelos de lenguaje deben implementar una función de análisis robusto asistida por expresiones regulares y una política de exactamente un (1) reintento inmediato antes de declarar una falla crítica en el parseo.

Módulo de Usabilidad y Compatibilidad Visual

- **RNF-9 (Portabilidad Serverless en la Nube):** La aplicación debe ser completamente compatible con el entorno Serverless de Vercel, requiriendo la importación de `pdf-parse` desde su distribución ligera (`pdf-parse/lib/pdf-parse.js`) para evitar fallos de compilación en producción.
- **RNF-10 (Diseño UI Consistente y Minimalista):** La interfaz debe basarse en un conjunto unificado de tokens de diseño declarados en las variables globales de CSS (`globals.css`), con componentes reutilizables de tipo `Card` y `Button` y paletas de colores oscuras optimizadas para reducir la fatiga visual.
- **RNF-11 (Renderizado Responsivo de Elementos Visuales):** El componente `MindMap.js` debe autoadaptarse proporcionalmente al espacio del contenedor dinámico, utilizando elementos vectoriales escalables (SVG) que garanticen la legibilidad del contenido tanto en pantallas de escritorio como en dispositivos portátiles.

5.1.3. Arquitectura General de la Solución

La solución se estructura bajo un enfoque modular y por capas que desacopla las responsabilidades del sistema, agiliza el desarrollo paralelo entre los integrantes del equipo y

garantiza su mantenibilidad futura.

Stack Tecnológico Seleccionado

Para maximizar la velocidad de respuesta, garantizar latencias mínimas y cumplir con las restricciones temporales del hackathon, se seleccionó un ecosistema tecnológico unificado basado en JavaScript y cómputo en el borde:

- **Frontend: React.js (Next.js 14+ App Router)** estructurado en múltiples rutas: `/login` para autenticación, `/dashboard` para el panel de sesiones pasadas, `/class/new` para el loop de clase en vivo, y `/class/[id]` para la visualización de sesiones guardadas. Centraliza los estados dinámicos e interactivos de la sesión y renderiza mapas cognitivos visuales mediante `markmap-lib` y `markmap-view`, y contenido Markdown mediante `react-markdown`.
- **Backend: Node.js (Next.js API Routes)** configurado mediante endpoints serverless desacoplados (`/api/*`). Funciona como la capa de abstracción, validación de contratos JSON y orquestación de llamadas hacia los servicios de inferencia de IA. Los siete endpoints (`/api/transcribe`, `/api/concepts`, `/api/upload-material`, `/api/quiz`, `/api/reinforcement`, `/api/chatbot`, `/api/finish-class`) son funciones puras: reciben JSON o FormData y devuelven JSON, sin acceso directo a la base de datos.
- **Base de Datos y Autenticación: Supabase (PostgreSQL en la nube con Row Level Security)**. Provee autenticación integrada (Google OAuth y correo/contraseña) mediante `@supabase/ssr`, y una tabla `classes` con RLS que garantiza el aislamiento de datos entre usuarios. La persistencia es gestionada exclusivamente desde el cliente de Next.js usando el SDK de Supabase, sin exponer la base de datos desde los endpoints de inferencia.
- **Componente de IA: API de Groq** integrada como el motor cognitivo central. Se utiliza `whisper-large-v3-turbo` para la conversión de voz a texto, `openai/gpt-oss-20b` para las tareas de extracción de conceptos y generación de micro-quizzes (menor latencia, respuestas breves), y `openai/gpt-oss-120b` para las tareas de mayor complejidad semántica: resúmenes de PDF, refuerzo cognitivo, chatbot RAG e informe de cierre de sesión.
- **Despliegue: Vercel (Serverless)**. Las variables de entorno `GROQ_API_KEY`, `NEXT_PUBLIC_SUPABASE_U` y `NEXT_PUBLIC_SUPABASE_ANON_KEY` se configuran en el panel de Vercel y nunca son expuestas al repositorio de código fuente.

5.2. Descripción Detallada del Prototipo Desarrollado (Demo)

Esta sección describe el flujo completo del Producto Mínimo Viable (MVP) desplegado en producción sobre Vercel (<https://vibe-learning-gamma.vercel.app>) para la evaluación del jurado.

5.2.1. Módulos Core Implementados en el MVP

La demo funcional integra los siguientes componentes clave en una única experiencia de usuario cohesionada:

1. **Módulo de Autenticación:** Página `/login` con registro e inicio de sesión por correo/contraseña y acceso con Google OAuth. El middleware de Next.js protege automáticamente las rutas `/dashboard` y `/class/*`.
2. **Panel de Sesiones:** Dashboard en `/dashboard` que lista todas las clases anteriores del usuario autenticado, recuperadas desde Supabase y ordenadas cronológicamente, con acceso directo a cada sesión guardada.
3. **Loop de Clase en Vivo:** La ruta `/class/new` centraliza el ciclo completo de la sesión educativa activa: transcripción en vivo, extracción de conceptos, micro-quizzes, andamiaje cognitivo, chatbot RAG y finalización con persistencia.
4. **Motor de Inferencia IA (Groq):** Suite de siete endpoints serverless desacoplados que orquestan los modelos de lenguaje para transcribir, analizar, evaluar, reforzar y resumir de forma autónoma y en tiempo real.
5. **Módulo de Andamiaje Visual:** Componente `<MindMap>` basado en SVG dinámico que renderiza mapas conceptuales interactivos ante fallos de comprensión y al finalizar la sesión.
6. **Chatbot RAG Flotante:** Asistente contextual que combina la transcripción acumulada (truncada a ~ 3000 palabras) con el resumen del PDF cargado para responder preguntas puntuales del estudiante durante la clase.
7. **Vista de Clase Guardada:** La ruta `/class/[id]` permite al usuario consultar el resumen en Markdown, el mapa mental SVG y descargar la transcripción completa de cualquier sesión anterior.

5.2.2. Flujo de Ejecución Completo de la Demo

El ciclo de vida completo de una sesión en VibeLearning se desarrolla en las siguientes etapas secuenciales:

1. **Autenticación:** El estudiante accede a `/login` y se autentica con su cuenta de correo o Google. Supabase establece una sesión segura mediante cookies HTTP-only. El middleware redirige al usuario autenticado directamente a `/dashboard`.
2. **Inicio de Clase:** Desde el dashboard, el alumno hace clic en “Nueva Clase” y es dirigido a `/class/new`. Opcionalmente, puede cargar el PDF del material bibliográfico de la asignatura. El endpoint `/api/upload-material` extrae y resume el contenido del archivo, almacenando el resumen en el estado de React como base de conocimiento fija de la sesión.

3. **Transcripción en Vivo:** El alumno activa el micrófono. El sistema utiliza la API `MediaRecorder` del navegador para capturar el audio en fragmentos de 7 segundos. Cada *chunk* es enviado automáticamente a `/api/transcribe`, que invoca a `whisper-large-v3-turbo` en Groq y devuelve el texto correspondiente en menos de 1.5 segundos. El texto se concatena al estado `transcript` de la sesión y se muestra en la pantalla en tiempo real.
4. **Ventaneo Semántico y Extracción de Conceptos:** El frontend monitorea la longitud del `transcript` y, cada vez que la ventana acumulada supera el equivalente a entre 90 y 120 segundos de exposición (12 a 15 *chunks*), envía dicha ventana al endpoint `/api/concepts`. El modelo `openai/gpt-oss-20b` extrae entre 3 y 5 conceptos clave estructurados en JSON (`name + summary`), que son renderizados en un panel lateral de la interfaz.
5. **Micro-Quiz de Active Recall:** Inmediatamente después de obtener los nuevos conceptos, el sistema envía la lista al endpoint `/api/quiz`. El modelo genera una pregunta de opción múltiple (A, B, C) enfocada en la idea principal del segmento. La pregunta se despliega como un banner no bloqueante en la parte superior de la pantalla, sin interrumpir la lectura del transcript ni la exposición del docente. El alumno selecciona su respuesta con un solo clic.
6. **Evaluación y Andamiaje Cognitivo:** El frontend compara la respuesta del alumno con el campo `correct` devuelto por el endpoint. Si la respuesta es correcta, se muestra un indicador visual de confirmación verde y el flujo continúa. Si la respuesta es incorrecta, el sistema realiza automáticamente una petición POST a `/api/reinforcement` con el nombre y resumen del concepto fallido. El modelo `openai/gpt-oss-120b` genera un resumen de apoyo de 3 a 4 líneas y una estructura Markdown jerárquica que el componente `<MindMap>` convierte en un árbol SVG interactivo, desplegado en un panel lateral de refuerzo.
7. **Asistencia RAG con el Chatbot:** En cualquier momento de la sesión, el alumno puede abrir el panel de chat flotante y escribir una pregunta. El frontend ensambla el *payload* adjuntando las últimas ~3000 palabras de la transcripción acumulada y el resumen del PDF cargado, y los envía a `/api/chatbot`. El modelo `openai/gpt-oss-120b` responde en texto plano, sin Markdown, con un máximo de 110 tokens, garantizando respuestas concisas y legibles directamente en el panel de chat.
8. **Finalización y Persistencia:** El alumno hace clic en “Finalizar Clase”. El sistema detiene la captura del micrófono y envía la transcripción completa junto con todos los conceptos acumulados al endpoint `/api/finish-class`. El modelo `openai/gpt-oss-120b` genera un resumen ejecutivo de hasta 400 palabras en Markdown, un mapa mental jerárquico global y un título descriptivo de hasta 6 palabras. El frontend recibe este objeto, inserta el registro completo de la sesión (título, transcripción, conceptos, resumen, mapa mental, resumen del PDF y resultados de quizzes) en la tabla `classes` de Supabase vinculado al `user_id` del alumno autenticado, y redirige al usuario al `/dashboard`, donde la nueva clase ya aparece disponible.

9. **Revisión Post-Clase:** Desde el dashboard, el alumno puede acceder en cualquier momento a cualquier sesión anterior a través de `/class/[id]`, donde visualiza el resumen renderizado en Markdown, el mapa mental interactivo SVG y tiene la opción de descargar la transcripción completa de la sesión.

5.2.3. Contrato de Datos entre Frontend y Endpoints de IA

La siguiente tabla resume los contratos de datos inmutables que rigen la comunicación entre la capa de presentación y los microservicios de inferencia:

Endpoint	Input	Output (JSON)
<code>/api/transcribe</code>	FormData: audio (blob webm)	<code>{"text": "..."} </code>
<code>/api/concepts</code>	<code>{"transcript": "..."} </code>	<code>{"concepts": [...] } </code>
<code>/api/upload-material</code>	FormData: pdf	<code>{"summary": "..."} </code>
<code>/api/quiz</code>	<code>{"concepts": [...] } </code>	<code>{"concept", "question", ... } </code>
<code>/api/reinforcement</code>	<code>{"concept_name", concept_summary"} </code>	<code>{"markdown": "..."} </code>
<code>/api/chatbot</code>	<code>{"question", "material_summary", "transcript"} </code>	<code>{"answer": "..."} </code>
<code>/api/finish-class</code>	<code>{"transcript", concepts": [...] } </code>	<code>{"title", "final_summary"} </code>

5.3. Estrategia de Integración de IA y Control de Comportamiento

Debido a la naturaleza crítica de los entornos educativos, la integración de la IA no se dejó al libre albedrío del modelo. Se aplicaron dos técnicas fundamentales de control:

5.3.1. Estructuración del Prompting y System Role

Se inyectó un rol de sistema (*System Prompt*) inmutable en cada endpoint que delimita estrictamente las fronteras del conocimiento de la IA, forzándola a responder únicamente bajo criterios pedagógicos preestablecidos y en formatos de datos estrictos. Para los endpoints que producen JSON estructurado (`/api/concepts`, `/api/quiz`), el prompt especifica el esquema exacto de respuesta y prohíbe explícitamente la inclusión de texto adicional fuera del objeto JSON. Para los endpoints de respuesta en lenguaje natural (`/api/chatbot`), el prompt restringe la salida a texto plano sin Markdown y limita el volumen de respuesta a 110 tokens.

5.3.2. Mitigación de Alucinaciones y Formateo Determinista

Para evitar respuestas erróneas o inventadas (alucinaciones), se implementó un flujo de validación posterior al LLM. Todos los endpoints que esperan JSON estructurado aplican un parser robusto asistido por expresiones regulares que extrae el bloque JSON incluso cuando el modelo incluye texto circundante no solicitado. Si el JSON extraído no cumple con la

estructura esperada por el contrato de datos, el software ejecuta automáticamente un único reintento inmediato. Si el segundo intento también falla, el endpoint devuelve un objeto de error controlado (`{skip:true}` o `{error}`) que el frontend interpreta para continuar el flujo sin exponer un comportamiento errático al usuario. Adicionalmente, ante errores HTTP 429 por saturación de cuota en la capa gratuita de Groq, los endpoints aplican la misma política de respuesta controlada, garantizando la continuidad operativa del sistema.

6. Impacto Esperado y Conclusiones

6.1. Métricas de Éxito Educativo y Tecnológico

Para evaluar el desempeño y el impacto multidimensional de la plataforma VibeLearning durante su fase de validación como Producto Mínimo Viable (MVP), se han definido indicadores clave de rendimiento (KPIs) agrupados en dos dimensiones: la eficiencia de la arquitectura de software y la efectividad pedagógica del modelo de andamiaje cognitivo.

6.1.1. Indicadores de Rendimiento Tecnológico (KPIs Técnicos)

- **Latencia de Inferencia Sincrónica (KPI-T1):** El tiempo promedio entre el envío del fragmento binario de audio de 7 segundos y el renderizado del texto transcrito no debe superar los 1,5 segundos, aprovechando la infraestructura de aceleración de Groq.
- **Tasa de Efectividad en el Parseo Estructurado (KPI-T2):** El parser robusto basado en expresiones regulares implementado en los endpoints semánticos debe alcanzar una precisión mínima del 98 % en la interpretación de objetos JSON válidos al aplicar la política de un (1) reintento automatizado.
- **Resiliencia ante Límites de Consumo (KPI-T3):** El sistema debe registrar un 100 % de continuidad operativa frente a excepciones de saturación de cuota (error HTTP 429), transformando el fallo en una respuesta controlada de tipo `{skip:true}` sin interrumpir el ciclo de vida del frontend.
- **Eficiencia en la Compresión de Contexto RAG (KPI-T4):** El mecanismo de truncamiento dinámico en el chatbot debe limitar el volumen de datos históricos de la sesión a las últimas ~3000 palabras, optimizando el consumo de tokens en un 40 % en comparación con un flujo acumulativo lineal sin truncamiento.
- **Integridad de la Persistencia (KPI-T5):** El 100 % de las sesiones finalizadas por usuarios autenticados debe resultar en un registro correctamente insertado en la tabla `classes` de Supabase, verificable desde `/dashboard` y accesible en `/class/[id]`, sin fugas de datos entre cuentas de usuario distintas.

6.1.2. Indicadores de Éxito Educativo (KPIs Pedagógicos)

- **Reducción del Tiempo de Preparación Administrativa (KPI-E1):** El uso de la plataforma debe reducir en un 100 % el tiempo que el docente dedica manualmente al diseño de reactivos de evaluación formativa durante la sesión, delegando la creación automática de micro-quizzes y mapas mentales al motor de IA.
- **Incremento del Enfoque y Evocación Activa (KPI-E2):** Se proyecta un incremento mínimo del 35 % en la tasa de participación interactiva y retención inmediata de los alumnos en comparación con el modelo expositivo tradicional, medido a través

del ratio de respuestas capturadas por los banners flotantes activados tras cada ciclo de ventaneo de entre 90 y 120 segundos.

- **Efectividad del Andamiaje ante el Rezago (KPI-E3):** Lograr que al menos el 85 % de los estudiantes que registren una respuesta incorrecta en un micro-quiz reviertan el sesgo de comprensión de forma autónoma en la siguiente evaluación, guiados por el resumen de soporte y el mapa mental SVG interactivo generados automáticamente.
- **Adopción del Repositorio de Clases (KPI-E4):** Al menos el 70 % de los usuarios registrados debe acceder al menos una vez a su panel de clases pasadas dentro de las 24 horas posteriores a finalizar su primera sesión, validando la utilidad percibida del repositorio personal de aprendizaje persistido en la nube.

6.2. Conclusiones

6.2.1. Conclusiones del Desarrollo del Prototipo

El diseño e implementación de VibeLearning demuestra la viabilidad técnica de interceptar y transformar la dinámica tradicional de la clase magistral pasiva mediante una arquitectura de inferencia de inteligencia artificial de ultra baja latencia integrada con un sistema de autenticación y persistencia en la nube. El desarrollo del prototipo arrojó cuatro hallazgos fundamentales:

- **Viabilidad de la Inferencia Concurrente en el Borde:** La segmentación del flujo continuo de audio en *chunks* temporales fijos de 7 segundos demostró ser el balance óptimo para equilibrar la carga computacional en el frontend y evitar la saturación de los tokens por minuto (TPM) en la infraestructura de Groq, validando que es posible ofrecer una experiencia sincrónica sin desplegar costosos servidores dedicados.
- **Efectividad del Andamiaje Cognitivo No Intrusivo:** La automatización de micro-evaluaciones basadas en técnicas de evocación activa gatilladas por ventaneo semántico probó que se puede monitorear y corregir el sesgo de comprensión de los estudiantes en tiempo real. La generación dinámica de mapas mentales SVG ante respuestas incorrectas alivia la carga cognitiva extrínseca sin interrumpir el ritmo expositivo del docente.
- **Escalabilidad del Modelo RAG para Asistencia Contextual:** La combinación de la transcripción acumulada (truncada dinámicamente) con el resumen del material bibliográfico pre-clase demostró ser un mecanismo efectivo para mantener la relevancia contextual de las respuestas del chatbot a lo largo de toda la sesión, incluso en condiciones de limitación de tokens de las capas gratuitas de inferencia.
- **Privacidad y Soberanía de Datos mediante Autenticación y RLS:** El enfoque de persistencia autenticada sobre Supabase con Row Level Security valida un paradigma escalable para la integración de tecnologías de IA en instituciones educativas. Al aislar los datos de cada usuario a nivel del motor de base de datos (no en la capa de

aplicación), el sistema garantiza que la información del aula —transcripciones, materiales bibliográficos y resultados de evaluaciones— esté disponible exclusivamente para el alumno que la generó, sin riesgos de exposición cruzada entre cuentas.

Bibliografía

- [Desire2Learn, 2023] Desire2Learn (2023). El desafío de la retención estudiantil en la educación superior de américa latina. Technical report, D2L Corporation.
- [Karpicke, 2012] Karpicke, J. D. (2012). Retrieval-based learning: Active retrieval promotes long-term learning. *Current Directions in Psychological Science*, 21(3):157–163.
- [Lewis et al., 2020] Lewis, P., Perez, E., Piktus, A., Petroni, F., Lewis, M., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474.
- [MINEDU, 2019] MINEDU (2019). Informe sobre la deserción en las universidades públicas y privadas del Perú. Technical report, MINEDU, Lima, Perú.
- [Ramos-Huenteo and Espinoza-Valenzuela, 2021] Ramos-Huenteo, P. and Espinoza-Valenzuela, D. (2021). Factores académicos asociados a la deserción universitaria: Un estudio en el contexto peruano. *Horizontes. Revista de Investigación en Ciencias de la Educación*, 5(19):745–758.
- [Teng et al., 2024] Teng, Y., Zhang, J., and Weng, X. (2024). Investigating the utilization and impact of large language model-based intelligent teaching assistants in flipped classrooms. *Education and Information Technologies*.
- [UNESCO, 2023] UNESCO (2023). *Global education monitoring report 2023: Technology in education: A tool on whose terms?* UNESCO Publishing.